

기계학습의 기초와 활용

Introduction to Physics-informed neural network, PINN

Hojun Lee

School of ICT, Robotics & Mechanical Engineering
Hankyong National University

2026. 04. 02 [Sat]



Contents

Research Contents

Conclusion And Future Works


1. Introduction (1)

▪ Overview

PINN(Physics-informed neural network)이란 미분 방정식으로 설명되는 물리 법칙을 손실 함수에 통합하여 기초 물리성을 거스르지 않는 해를 얻는 방향으로 학습 과정을 이끄는 신경망

PINN은 다음과 같은 작업에 활용

- PDE(Partial differential equation) 및 ODE(Ordinary differential equation)의 해 근사화.
- 제한된 데이터로부터 모델 파라미터 추정과 같은 역문제 풀기.



1. Introduction (2)

▪ Advantage of PINN

기존의 Data-driven 접근법과는 달리,

1. 사전 물리학 지식을 사용
2. 훈련 데이터셋 외부에서 더욱 정확한 예측을 수행
3. 제한적이거나 잡음이 있는 훈련 데이터에 더욱 효과적

기존의 수치해석 접근법과는 달리,

1. 메시 미사용
2. 고차원 PDE 해 근사화 가능
3. 미지의 PDE 계수나 ODE 계수와 같은 결측 모델 파라미터의 해를 산출 가능
4. 경계 데이터가 없는 잘못 설정된 문제의 해 산출 가능
5. 희소 측정값 또는 잡음이 있는 측정값을 쉽게 통합 가능


▪ Limitations of PINN

1. 제한된 수렴 이론
2. 통일된 훈련 전략 부족
3. 고차 도함수 계산에 드는 연산 비용 발생
4. PDE 해의 고주파 및 멀티 스케일 성분 학습이 어려움

2. Structure

■ Structure of PINN


- ✓ PINN은 최적화 알고리즘을 사용하여 지정된 **물리정보 손실 함수**의 값이 허용 가능한 수준으로 감소할 때까지 신경망의 파라미터를 반복적으로 업데이트하여 신경망이 미분 방정식의 해에 도달



예를 들어 다음과 같은 MCK System을 고려할 때,

$$m\ddot{x}(t) + c\dot{x}(t) + kx(t) = 0$$

with initial conditions $x(0) = x_0, \dot{x}(0) = \dot{x}_0$



MCK System에 대한 PINN 구조는 다음과 같이 표현할 수 있다.

$$loss_{data}(\sigma) = \frac{1}{N} \sum_{i=1}^N |x_{pred}(t_i; \sigma) - x_{meas}(t_i)|^2$$

$$loss_{cond}(\sigma) = \frac{1}{2} |x_{pred}(t_0, \sigma) - x_0|^2 + \frac{1}{2} |\dot{x}_{pred}(t_0, \sigma) - \dot{x}_0|^2$$

$$loss_{physics}(\sigma) = \frac{1}{M} \sum_{i=1}^M \left| m \frac{d^2}{dt^2} x(t_i; \sigma) + c \frac{d}{dt} x(t_i; \sigma) + kx(t_i; \sigma) - f(t_i) \right|^2$$


$$loss(\sigma) = loss_{data}(\sigma) + \lambda_1 loss_{cond}(\sigma) + \lambda_2 loss_{physics}(\sigma)$$

where λ : weight

3. Simple harmonic motion (1)

▪ Mathematical Modeling

✓ 일반적인 단순조화운동의 미분방정식과 일반해는 다음과 같은 형태를 가진다.



$$x(\ddot{t}) + \omega^2 x(t) = f(t)$$

with initial conditions $y(0) = y_0, \quad y(\dot{0}) = y_0$

$$x(t) = A \sin(\omega t + \phi), \quad \text{where } \omega = \sqrt{\frac{k}{m}}$$

✓ 초기 조건을 통해 진폭과 위상은 다음과 같이 산출할 수 있다.

$$x(t) = A \sin(\omega t + \phi), \quad v(t) = \frac{dx(t)}{dt} = A \omega \cos(\omega t + \phi)$$


$$\rightarrow x_0 = A \sin(\phi), \quad v_0 = A \omega \cos(\phi), \quad \rightarrow A \cos(\phi) = \frac{v_0}{\omega}$$

$$\rightarrow (A \sin(\phi))^2 + (A \cos(\phi))^2 = x_0^2 + \left(\frac{v_0}{\omega}\right)^2 = A^2 (\sin^2(\phi) + \cos^2(\phi)) = A^2 = x_0^2 + \left(\frac{v_0}{\omega}\right)^2$$


$$\rightarrow A = \sqrt{x_0^2 + \left(\frac{v_0}{\omega}\right)^2}, \quad \Phi = \tan^{-1} \left(\frac{\omega x_0}{v_0} \right)$$

3. Simple Harmonic Motion (3)

- PINN Structure (3)



✓ MK System에 대한 PINN 구조를 다음과 같이 구성하였다.
단, 경계 조건에 대한 손실 함수가 생략된 간략화 된 모델을 구축하였다.



$$loss_{data}(\sigma) = \frac{1}{N} \sum_{i=1}^N |x_{pred}(t_i; \sigma) - x_{meas}(t_i)|^2$$


$$loss_{physics}(\sigma) = \frac{1}{M} \sum_{i=1}^M \left| m \frac{d^2}{dt^2} x(t_i; \sigma) + kx(t_i; \sigma) - f(t_i) \right|^2$$

$$loss(\sigma) = loss_{data}(\sigma) + \lambda loss_{physics}(\sigma)$$

3. Simple harmonic motion (2)

Exact Solution Curve And Parameters

- ✓ 엄밀해 곡선과 노이즈가 섞인 데이터는 그래프 1에서 확인할 수 있다.
- ✓ 이때 사용된 파라미터는 아래의 표와 같다.



Ordinary Differential Equation Parameters		
Parameter	Value	Description
m	1	Mass
k	4	Spring coefficient


Data Generation Parameters		
Parameter	Value	Description
N_{TRAIN}	20	The number of training data containing a noise
$TMAX_{\text{TRAIN}}$	2	The time limitation of training data
$NOISE_{\text{STD}}$	0.05	The data noise standard deviation
N_{TEST}	1000	The number of test data
$TMAX_{\text{TEST}}$	10	The time limitation of test data

Ordinary Differential Equation Initial Value		
initial value		Description
x_0	1	Initial position
$\dot{x}_0$	1	Initial velocity

3. Simple harmonic motion (3)

■ Purely Data Driven Approach

✓ Data-driven으로만 학습된 모델의 경우 그래프 2와 같은 경향을 보인다.



Deep Learning Parameters		
Parameter	Value	Description
input_size	1	For time t
hidden_size	32	Two hidden layers with 32 neurons each
output_size	1	For position $x(t)$
activation function	tanh	Hyperbolic tangent function
nepochs	1000	Number of training epochs
learning_rate	$5e^{-3}$	The time limitation of test data


✓ 그래프 2에서 확인되듯이, 20개의 데이터에 대해 과대적합 현상이 나타났다.

✓ 또한, 학습 데이터가 종료되는 $t \geq 2$ 지점부터는 외삽에 대한 불안정성이 크게 증가한다.

3. Simple harmonic motion (4)

▪ Physics Informed Neural Network

✓ PINN으로 학습된 모델의 경우 그래프 3와 같은 경향을 보인다.



Deep Learning Parameters		
Parameter	Value	Description
TMAX_PHYS	7	Maximum time for physics loss evaluation points
N_PHYS	1000	Number of physics loss evaluation points
lambda_	1	Weighting factor for the physics loss component


- ✓ 기존의 데이터 기반(Data-driven) 방식과 달리, 외삽 구간에서도 높은 안정성을 확인하였다.
- ✓ 다만 불안정성이 잔존하여 추가적인 개선이 요구되며, 이에 대해 하이퍼 파라미터 최적화가 이루어지지 않았다는 점도 고려해야 한다.
- ✓ 또한, 학습 과정에서 손실 수렴 속도가 기존 데이터 기반 방식보다 느렸다는 점도 중요한 쟁점이다.

Contents

Research Contents

Conclusion And Future Works

4. Conclusion And Future Works



$$loss_{data}(\sigma) = \frac{1}{N} \sum_{i=1}^N |x_{pred}(t_i; \sigma) - x_{meas}(t_i)|^2$$

$$loss_{physics}(\sigma) = \frac{1}{M} \sum_{i=1}^M \left| m \frac{d^2}{dt^2} x(t_i; \sigma) + kx(t_i; \sigma) - f(t_i) \right|^2$$

$$loss(\sigma) = loss_{data}(\sigma) + \lambda loss_{physics}(\sigma)$$

- ✓ PINN(Physics-Informed Neural Network)은 미분 방정식 형태의 물리 법칙을 손실 함수에 통합함으로써, 물리적 타당성을 보장하는 해를 도출하는 신경망 모델이다.
- ✓ 질량-스프링 시스템(Mass-Spring System)을 통해 모델을 검증한 결과, 다음과 같은 분석을 얻었다.
 1. 노이즈가 포함된 데이터 환경에서도 기존 데이터 기반 방식 대비 우수한 외삽 안정성을 확보함.
 2. 다만, 학습 과정에서의 손실 함수 수렴 속도가 상대적으로 느리며, 외삽 구간에서의 완전한 안정성 확보를 위한 추가 개선이 필요함.